

Método de Momentos: Propriedades Assintóticas

Jaqueline Lamas da Silva

30/06/2026

Sumário:

- Introdução
- Estimador de momentos
- Normalidade Assintótica
- Normalidade Assintótica (PROVA)
- Método Delta Generalizado
- Exemplo
- Simulação
- Referências

Introdução

O método determina estimadores estabelecendo uma relação entre os momentos amostrais m_n e os momentos populacionais $h(\theta)$.

Estimador de momentos

Sejam $X_1, \dots, X_n$ variáveis aleatórias i.i.d com distribuição,

$$X \sim f(x, \boldsymbol{\theta}), \boldsymbol{\theta} \in \Theta \subset \mathbb{R}^k, k \geq 1$$

Considere a seguinte função

$$\boldsymbol{g}(X) = \begin{bmatrix} g_1(X) \\ \vdots \\ g_k(X) \end{bmatrix}_{k \times 1}.$$

Os momentos populacionais são obtidos da seguinte forma:

$$\mathbf{h}(\boldsymbol{\theta}) = \begin{bmatrix} E_{\theta} [g_1(X)] \\ \vdots \\ E_{\theta} [g_k(X)] \end{bmatrix} = \begin{bmatrix} h_1(\boldsymbol{\theta}) \\ \vdots \\ h_k(\boldsymbol{\theta}) \end{bmatrix}_{k \times 1}$$

Com base nisso, o estimador dos momentos $\hat{\boldsymbol{\theta}}_M$ é obtido pela solução das equações:

$$\mathbf{h}(\boldsymbol{\theta}) = \mathbf{m}_n.$$

Normalidade Assintótica

Suposições:

- $\mathbb{P}_{\boldsymbol{\theta}} \|g\|^2 = E_{\boldsymbol{\theta}} \left[\sum_{j=1}^k g_j(X)^2 \right] < \infty$;
- $h_j(\boldsymbol{\theta}) < \infty, j = 1, \dots, 2k$ (caso simples $g_j(X) = X^j$);
- $\mathbf{H}(\boldsymbol{\theta})$ deve ter posto completo e seus elementos devem ser funções contínuas de $\boldsymbol{\theta}$.

Teorema:

Considerando o cenário proposto e assumindo que as suposições descritas sejam válidas, verifica-se que:

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_M - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}_k(\mathbf{0}, [\mathbf{H}(\boldsymbol{\theta}_0)]^{-1} \boldsymbol{\Sigma} \{[\mathbf{H}(\boldsymbol{\theta}_0)]^{-1}\}^{\top}).$$

Normalidade Assintótica (PROVA)

Considere $\boldsymbol{\lambda} \in \mathbb{R}^k$ um vetor arbitrário, podemos definir uma sequência de variáveis aleatórias i.i.d da seguinte forma:

$$\begin{aligned} U_i &= \boldsymbol{\lambda}^\top [\mathbf{g}(X_i) - \mathbf{h}(\boldsymbol{\theta})] = \\ &= \sum_{j=1}^k \lambda_j [g_j(X_i) - h_j(\boldsymbol{\theta})] \end{aligned}$$

Não é difícil mostrar que $E_{\boldsymbol{\theta}} [U_i] = 0$:

$$\begin{aligned} E_{\boldsymbol{\theta}} [U_i] &= E_{\boldsymbol{\theta}} [\boldsymbol{\lambda}^\top \{\mathbf{g}(X_i) - \mathbf{h}(\boldsymbol{\theta})\}] = \\ &= \boldsymbol{\lambda}^\top \{E_{\boldsymbol{\theta}} [\mathbf{g}(X_i) - \mathbf{h}(\boldsymbol{\theta})]\} = \\ &= \boldsymbol{\lambda}^\top \{E_{\boldsymbol{\theta}} [\mathbf{g}(X_i)] - \mathbf{h}(\boldsymbol{\theta})\} = \\ &= \boldsymbol{\lambda}^\top \{\mathbf{h}(\boldsymbol{\theta}) - \mathbf{h}(\boldsymbol{\theta})\} = \\ &= \boldsymbol{\lambda}_{1 \times k}^\top \{\mathbf{0}\}_{k \times 1} = \\ &= 0. \end{aligned}$$

Além disso, $Var_{\theta} [U_i] = \boldsymbol{\lambda}^T \boldsymbol{\Sigma} \boldsymbol{\lambda}$, onde $\boldsymbol{\Sigma} = Cov_{\theta} [\boldsymbol{g}(X_i)]$

$$\begin{aligned} Var_{\theta} [U_i] &= Var_{\theta} [\boldsymbol{\lambda}^T \{\boldsymbol{g}(X_i) - \boldsymbol{h}(\boldsymbol{\theta})\}] = \\ &= Var_{\theta} [\boldsymbol{\lambda}^T \boldsymbol{g}(X_i)] = \\ &= \boldsymbol{\lambda}^T Cov_{\theta} [\boldsymbol{g}(X_i)] \boldsymbol{\lambda} \\ &= \boldsymbol{\lambda}_{1 \times k}^T \boldsymbol{\Sigma}_{k \times k} \boldsymbol{\lambda}_{k \times 1}. \end{aligned}$$

Como as variáveis aleatórias U_i são independentes e identicamente distribuídas, com média 0 e variância $\boldsymbol{\lambda}^T \boldsymbol{\Sigma} \boldsymbol{\lambda}$, pelo TCL, temos que:

$$\frac{1}{\sqrt{n}} \sum_{i=1}^n U_i \xrightarrow{d} N(0, \boldsymbol{\lambda}^T \boldsymbol{\Sigma} \boldsymbol{\lambda})$$

Temos também que

$$\begin{aligned}
 \frac{1}{\sqrt{n}} \sum_{i=1}^n U_i &= \frac{1}{\sqrt{n}} \sum_{i=1}^n \boldsymbol{\lambda}^\top [\mathbf{g}(X_i) - \mathbf{h}(\boldsymbol{\theta})] = \\
 &= \boldsymbol{\lambda}^\top \frac{1}{\sqrt{n}} \left[\sum_{i=1}^n \mathbf{g}(X_i) - n \cdot \mathbf{h}(\boldsymbol{\theta}) \right] = \\
 &= \boldsymbol{\lambda}^\top \sqrt{n} \left[\frac{1}{n} \sum_{i=1}^n \mathbf{g}(X_i) - \mathbf{h}(\boldsymbol{\theta}) \right] = \\
 &= \boldsymbol{\lambda}^\top \sqrt{n} [\mathbf{m}_n - \mathbf{h}(\boldsymbol{\theta})].
 \end{aligned}$$

Ou seja,

$$\boldsymbol{\lambda}^\top \sqrt{n} [\mathbf{m}_n - \mathbf{h}(\boldsymbol{\theta})] \xrightarrow{d} N(0, \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda}).$$

Teorema de Cramér-Wold:

$$\mathbf{Y}_n \xrightarrow{d} \mathbf{Y} \iff \boldsymbol{\lambda}^\top \mathbf{Y}_n \xrightarrow{d} \boldsymbol{\lambda}^\top \mathbf{Y} \quad \text{para todo vetor fixo } \boldsymbol{\lambda}$$

Como U_i foi definida para um $\boldsymbol{\lambda}$ qualquer e mostramos o seguinte:

$$\boldsymbol{\lambda}^\top \sqrt{n} [\mathbf{m}_n - \mathbf{h}(\boldsymbol{\theta})] \xrightarrow{d} \boldsymbol{\lambda}^\top \mathbf{J}, \quad \text{onde } \mathbf{J} \sim \mathcal{N}_k(\mathbf{0}_{k \times 1}, \boldsymbol{\Sigma}_{k \times k}) \text{ e } \boldsymbol{\lambda}^\top \mathbf{J} \sim N(0, \boldsymbol{\lambda}^\top \boldsymbol{\Sigma} \boldsymbol{\lambda}).$$

Resultado 1:

$$\sqrt{n} [\mathbf{m}_n - \mathbf{h}(\boldsymbol{\theta})] \xrightarrow{d} \mathbf{J}.$$

Expansão em série de Taylor:

Considere $\mathbf{u}$ um vetor em $\mathbb{R}^k$, vamos expandir a função $\mathbf{h}(\boldsymbol{\theta}_0 + \frac{1}{\sqrt{n}}\mathbf{u})$ em torno de $\boldsymbol{\theta}_0$.

Para isso, considere também $\mathbf{H}(\boldsymbol{\theta})_{k \times k} = \frac{\partial \mathbf{h}(\boldsymbol{\theta})}{\partial \boldsymbol{\theta}^\top}$, ou seja,

$$\mathbf{H}(\boldsymbol{\theta})_{k \times k} = \begin{bmatrix} \frac{\partial h_1(\boldsymbol{\theta})}{\partial \theta_1} & \frac{\partial h_1(\boldsymbol{\theta})}{\partial \theta_2} & \dots & \frac{\partial h_1(\boldsymbol{\theta})}{\partial \theta_k} \\ \frac{\partial h_2(\boldsymbol{\theta})}{\partial \theta_1} & \frac{\partial h_2(\boldsymbol{\theta})}{\partial \theta_2} & \dots & \frac{\partial h_2(\boldsymbol{\theta})}{\partial \theta_k} \\ \vdots & & \ddots & \vdots \\ \frac{\partial h_k(\boldsymbol{\theta})}{\partial \theta_1} & \frac{\partial h_k(\boldsymbol{\theta})}{\partial \theta_2} & \dots & \frac{\partial h_k(\boldsymbol{\theta})}{\partial \theta_k} \end{bmatrix}.$$

Além disso, definimos $\boldsymbol{\theta}^* = \boldsymbol{\theta}_0 + \frac{1}{\sqrt{n}}t \cdot \mathbf{u}$, onde $0 \leq t \leq 1$ (entre $\boldsymbol{\theta}_0$ e $\boldsymbol{\theta}_0 + \frac{1}{\sqrt{n}}\mathbf{u}$):

- $t = 0, \boldsymbol{\theta}^* = \boldsymbol{\theta}_0$;
- $t = 1, \boldsymbol{\theta}^* = \boldsymbol{\theta}_0 + \frac{1}{\sqrt{n}}\mathbf{u}$;
- $\boldsymbol{\theta}^* \xrightarrow{n \rightarrow \infty} \boldsymbol{\theta}_0$.

Com isso, temos que:

$$h(\theta_0 + \frac{1}{\sqrt{n}}u) = h(\theta) \Big|_{\theta=\theta_0} + H(\theta) \Big|_{\theta=\theta^*} (\theta_0 + \frac{1}{\sqrt{n}}u - \theta_0)$$

Vamos adicionar e subtrair $H(\theta_0)(\theta_0 + \frac{1}{\sqrt{n}}u - \theta_0)$

$$\begin{aligned} h(\theta_0 + \frac{1}{\sqrt{n}}u) &= h(\theta_0) + H(\theta^*)(\theta_0 + \frac{1}{\sqrt{n}}u - \theta_0) + H(\theta_0)(\theta_0 + \frac{1}{\sqrt{n}}u - \theta_0) - H(\theta_0)(\theta_0 + \frac{1}{\sqrt{n}}u - \theta_0) = \\ &= h(\theta_0) + H(\theta^*)(\frac{1}{\sqrt{n}}u) + H(\theta_0)(\frac{1}{\sqrt{n}}u) - H(\theta_0)(\frac{1}{\sqrt{n}}u) = \\ &= h(\theta_0) + H(\theta^*)(\frac{1}{\sqrt{n}}u) + H(\theta_0)(\frac{1}{\sqrt{n}}u) - H(\theta_0)(\frac{1}{\sqrt{n}}u) = \\ &= h(\theta_0) + H(\theta_0)(\frac{1}{\sqrt{n}}u) + [H(\theta^*) - H(\theta_0)](\frac{1}{\sqrt{n}}u). \end{aligned}$$

Como $\theta^* \xrightarrow{n \rightarrow \infty} \theta_0$ e $H(\theta^*) \xrightarrow{n \rightarrow \infty} H(\theta_0)$, então

$$h(\theta_0 + \frac{1}{\sqrt{n}}u) = h(\theta_0) + H(\theta_0)(\frac{1}{\sqrt{n}}u) + o(1).$$

Após algumas manipulações, temos

$$\mathbf{h}(\boldsymbol{\theta}_0 + \frac{1}{\sqrt{n}}\mathbf{u}) - \mathbf{h}(\boldsymbol{\theta}_0) = \frac{1}{\sqrt{n}}\mathbf{H}(\boldsymbol{\theta}_0) \cdot \mathbf{u} + o(1)$$

$$\sqrt{n} \left[\mathbf{h}(\boldsymbol{\theta}_0 + \frac{1}{\sqrt{n}}\mathbf{u}) - \mathbf{h}(\boldsymbol{\theta}_0) \right] = \mathbf{H}(\boldsymbol{\theta}_0) \cdot \mathbf{u} + o(1)$$

Se considerarmos $\mathbf{u} = \sqrt{n}(\hat{\boldsymbol{\theta}}_M - \boldsymbol{\theta}_0)$ então $\mathbf{h}(\boldsymbol{\theta}_0 + \frac{1}{\sqrt{n}}\mathbf{u}) = \mathbf{h}(\hat{\boldsymbol{\theta}}_M) = \mathbf{m}_n$.

Com isso,

$$\sqrt{n} [\mathbf{m}_n - \mathbf{h}(\boldsymbol{\theta}_0)] = \mathbf{H}(\boldsymbol{\theta}_0) \cdot \sqrt{n}(\hat{\boldsymbol{\theta}}_M - \boldsymbol{\theta}_0) + o_p(1).$$

$$\sqrt{n} [\mathbf{H}(\boldsymbol{\theta}_0)]^{-1} [\mathbf{m}_n - \mathbf{h}(\boldsymbol{\theta}_0)] = \sqrt{n}(\hat{\boldsymbol{\theta}}_M - \boldsymbol{\theta}_0) + o_p(1).$$

Pelo *Resultado 1* podemos concluir que:

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_M - \boldsymbol{\theta}_0) \xrightarrow{d} \mathcal{N}_k(\mathbf{0}, [\mathbf{H}(\boldsymbol{\theta}_0)]^{-1} \boldsymbol{\Sigma} \{[\mathbf{H}(\boldsymbol{\theta}_0)]^{-1}\}^\top).$$

Método Delta Generalizado

Voltando ao resultado obtido anteriormente,

$$\sqrt{n} [\mathbf{m}_n - \mathbf{h}(\boldsymbol{\theta})] \xrightarrow{d} \mathcal{N}_k(\mathbf{0}_{k \times 1}, \boldsymbol{\Sigma}_{k \times k}).$$

Recorde que $\mathbf{m}_n = \mathbf{h}(\hat{\boldsymbol{\theta}}_M)$, com isso,

$$\sqrt{n} [\mathbf{h}(\hat{\boldsymbol{\theta}}_M) - \mathbf{h}(\boldsymbol{\theta})] \xrightarrow{d} \mathcal{N}_k(\mathbf{0}, \boldsymbol{\Sigma}).$$

Seja $\mathbf{h}^{-1}$ a função inversa. A matriz jacobiana de $\mathbf{h}^{-1}$, pelo Teorema da Função Inversa é a matriz inversa da jacobiana da função $\mathbf{h}(\boldsymbol{\theta})$, ou seja, é igual a $[\mathbf{H}(\boldsymbol{\theta})]^{-1}$. Portanto, podemos aplicar o Método Delta Generalizado para dizer que:

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_M - \boldsymbol{\theta}) \xrightarrow{d} \mathcal{N}_k(\mathbf{0}, [\mathbf{H}(\boldsymbol{\theta})]^{-1} \boldsymbol{\Sigma} \{[\mathbf{H}(\boldsymbol{\theta})]^{-1}\}^\top).$$

Desse modo, alcançamos o resultado de normalidade assintótica por dois caminhos diferentes.

Exemplo

Sejam $X_1, \dots, X_n$ variáveis aleatórias i.i.d com distribuição,

$$X \sim \text{Beta}(\alpha, \beta), \boldsymbol{\theta} = (\alpha, \beta)^\top \in \Theta = \{(\alpha, \beta) \in \mathbb{R}^2 : \alpha > 0, \beta > 0\}$$

$$\mathbf{g}(X) = \begin{bmatrix} X \\ X^2 \end{bmatrix}_{2 \times 1}$$

$$\mathbf{m}_n = \begin{bmatrix} \frac{1}{n} \sum_{i=1}^n X_i \\ \frac{1}{n} \sum_{i=1}^n X_i^2 \end{bmatrix}$$

$$\mathbf{h}(\boldsymbol{\theta}) = \begin{bmatrix} E_{\boldsymbol{\theta}}[X] \\ E_{\boldsymbol{\theta}}[X^2] \end{bmatrix} = \begin{bmatrix} \frac{\alpha}{\alpha+\beta} \\ \frac{\alpha}{\alpha+\beta} \cdot \frac{\alpha+1}{\alpha+\beta+1} \end{bmatrix}$$

Os momentos teóricos de ordem k de uma variável aleatória X com distribuição $\text{Beta}(\alpha, \beta)$ é dado

Resolvendo o sistema de equações:

$$\mathbf{h}(\boldsymbol{\theta}) = \mathbf{m}_n$$

$$\begin{cases} \frac{\alpha}{\alpha+\beta} = \frac{1}{n} \sum_{i=1}^n X_i \\ \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} = \frac{1}{n} \sum_{i=1}^n X_i^2 \end{cases},$$

temos que $\hat{\boldsymbol{\theta}}_M$ é $(\hat{\alpha}, \hat{\beta})^\top$ onde

$$\hat{\alpha} = \frac{\frac{1}{n} \sum_{i=1}^n X_i \cdot \left(\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n X_i^2 \right)}{\frac{1}{n} \sum_{i=1}^n X_i^2 - \left[\frac{1}{n} \sum_{i=1}^n X_i \right]^2} \quad \text{e} \quad \hat{\beta} = \frac{\left(1 - \frac{1}{n} \sum_{i=1}^n X_i \right) \cdot \left(\frac{1}{n} \sum_{i=1}^n X_i - \frac{1}{n} \sum_{i=1}^n X_i^2 \right)}{\frac{1}{n} \sum_{i=1}^n X_i^2 - \left[\frac{1}{n} \sum_{i=1}^n X_i \right]^2}.$$

O resultado assintótico nos diz que:

$$\sqrt{n}(\hat{\boldsymbol{\theta}}_M - \boldsymbol{\theta}) \xrightarrow{d} \mathcal{N}_2(\mathbf{0}, [\mathbf{H}(\boldsymbol{\theta})]^{-1} \boldsymbol{\Sigma} \{[\mathbf{H}(\boldsymbol{\theta})]^{-1}\}^\top).$$

onde $\boldsymbol{\Sigma} = \text{Cov}_{\boldsymbol{\theta}}(\mathbf{g}(X))$.

$$\Sigma = \begin{bmatrix} E_{\theta}[X^2] - \{E_{\theta}[X]\}^2 & E_{\theta}[X^3] - E_{\theta}[X^2] \cdot E_{\theta}[X] \\ E_{\theta}[X^3] - E_{\theta}[X^2] \cdot E_{\theta}[X] & E_{\theta}[X^4] - \{E_{\theta}[X^2]\}^2 \end{bmatrix},$$

isto é

$$\Sigma = \begin{bmatrix} \frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)} - \left(\frac{\alpha}{\alpha+\beta}\right)^2 & \frac{\alpha(\alpha+1)(\alpha+2)}{(\alpha+\beta)(\alpha+\beta+1)(\alpha+\beta+2)} - \left(\frac{\alpha}{\alpha+\beta}\right) \left(\frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}\right) \\ \frac{\alpha(\alpha+1)(\alpha+2)}{(\alpha+\beta)(\alpha+\beta+1)(\alpha+\beta+2)} - \left(\frac{\alpha}{\alpha+\beta}\right) \left(\frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}\right) & \frac{\alpha(\alpha+1)(\alpha+2)(\alpha+3)}{(\alpha+\beta)(\alpha+\beta+1)(\alpha+\beta+2)(\alpha+\beta+3)} - \left(\frac{\alpha(\alpha+1)}{(\alpha+\beta)(\alpha+\beta+1)}\right)^2 \end{bmatrix}.$$

E, a matriz jacobiana da função $\mathbf{h}(\boldsymbol{\theta})$ é

$$\mathbf{H}(\boldsymbol{\theta}) = \begin{bmatrix} \frac{\beta}{(\alpha + \beta)^2} & \frac{-\alpha}{(\alpha + \beta)^2} \\ \frac{\beta \cdot (2\alpha\beta + 2\alpha^2 + 2\alpha + \beta + 1)}{[(\alpha + \beta + 1)(\alpha + \beta)]^2} & \frac{-\alpha (\alpha + 1) (2\beta + 2\alpha + 1)}{(\alpha + \beta)^2} \end{bmatrix}.$$

Simulação

Amostras geradas pela distribuição

$$X \sim \text{Beta}(2, 3).$$

► Código

► Código

► Código

Tabela 1: Média das estimativas, erro padrão e erro padrão teórico para cada tamanho de amostra

		n=20			n=30			n=80			n=200			n=500		
	θ	$\hat{\theta}$	sd	ep	$\hat{\theta}$	sd	ep	$\hat{\theta}$	sd	ep	$\hat{\theta}$	sd	ep	$\hat{\theta}$	sd	ep
α	2	2.285	0.864	0.627	2.175	0.592	0.512	2.065	0.333	0.313	2.025	0.202	0.198	2.010	0.124	0.125
β	3	3.479	1.378	0.964	3.271	0.918	0.787	3.093	0.504	0.482	3.040	0.305	0.305	3.016	0.198	0.193

Figura 1: Histograma das estimativas do parâmetro e distribuição teórica para cada tamanho de amostra





Figura 2: Histograma das estimativas do parâmetro e distribuição teórica para cada tamanho de amostra



Referências

Leite, J. G., & Singer, J. M. (1989). *Métodos assintóticos em estatística: fundamentos e aplicações*.

Sen, P. K., Singer, J. M., & Pedroso-de-Lima, A. C. (2010). *From Finite Sample to Asymptotic Methods in Statistics*. Cambridge University Press.

Van der Vaart, A. W. (1998). *Asymptotic Statistics*. Cambridge University Press.